

Projet fil rouge : Analyse statistique des réseaux sociaux

Phase 1 : Analyse du besoin / cadrage

1. Contexte

Ce projet s'inscrit dans le domaine du marketing digital et de l'analyse des performances sur les réseaux sociaux. Les plateformes comme Instagram occupent une place centrale chez les jeunes adultes, notamment la tranche des 18–24 ans, qui y passent plusieurs heures par jour.

Une agence de marketing digital souhaite analyser les performances des publications Instagram d'un client (marque ou influenceur) afin de mieux comprendre les facteurs qui influencent l'engagement des Utilisateurs.

2. Problématique

L'objectif de ce projet est d'identifier les facteurs qui influencent l'engagement des publications Instagram. Plus précisément, on cherche à comprendre si les caractéristiques d'un post (type de contenu, hashtags, moment de publication, etc.) ont un impact sur le taux d'engagement généré.

Questions principales :

Q1 : Peut-on modéliser et prédire le taux d'engagement d'un post Instagram à partir de ses caractéristiques ?

Q2 : Peut-on prédire si un post sera à fort engagement (oui/non) à partir de ces mêmes variables, afin d'identifier les posts à fort potentiel ?

3. Variable cible et variables explicatives

Jeu de données :

Dataset « Instagram data »
Kaggle : 119 posts et 13 colonnes.

Variable à expliquer :

Y = taux d'engagement engagement

$$\text{Engagement} = \text{Likes} + \text{Comments} + \text{Shares}$$

Impressions

Variables explicatives envisagées :

- **Quantitatives** : Impressions, From Home, From Hashtags, From Explore, From Other, Saves, Comments, Shares, Likes, Profile Visits, Follows
- **Variables dérivées** : caption_length, hashtags_count
- **Textuelles** : Caption, Hashtags

4. Type de modèles envisagés

Dans un premier temps, des modèles de régression seront utilisés afin d'expliquer une variable quantitative (taux d'engagement). Dans un second temps, un problème de classification pourra être envisagé afin de prédire si un post atteint un niveau d'engagement élevé ou non.

Phase 2 : Exploration et préparation des données

L'objectif de cette phase est de comprendre la structure du jeu de données Instagram, de nettoyer les données si nécessaire et de réaliser une première analyse descriptive à l'aide de tableaux et de graphiques.

1. Import des données

Nous utilisons le dataset public « Instagram data » (Kaggle) contenant 119 posts d'un compte Instagram orienté data/programmation. Les variables disponibles incluent les impressions totales,

Les impressions par source (**From Home, From Hashtags, From Explore, From Other**),

Les interactions (**Likes, Comments, Shares, Saves**), les visites de profil, les abonnements, ainsi que la légende (**Caption**) et les hashtags du post.

2. Nettoyage des données

Nous vérifions d'abord la présence de 0 valeur manquante et pas de doublons dans le jeu de données afin d'évaluer la qualité des informations disponibles.

3. Transformation et création de nouvelles variables

Afin d'enrichir l'analyse, nous avons créé plusieurs variables dérivées à partir des champs textuels et des indicateurs de performance :

- **Longueur de la légende (caption_length)** : nombre de caractères de Caption pour chaque post.
- **Nombre de hashtags (hashtags_count)** : nombre de hashtags présents dans la chaîne Hashtags, obtenu en comptant les mots séparés par des espaces.
- **Taux d'engagement (engagement)** :

Engagement = Likes+Comments+Shares

Impressions

<i>Index</i>	<i>Caption_length</i>	<i>Hashtags_Count</i>	<i>Engagement</i>
0	112	22	0.044897959183673466
1	187	18	0.04542083796811272
2	117	18	0.03556329271325541
3	202	11	0.05079505300353357
4	178	29	0.05242255758538523

Ce qui mesure le niveau d'interaction relatif à la visibilité du post.

Ces variables seront utilisées comme variable cible (engagement) et comme variables explicatives (par exemple caption_length, hashtags_count) dans les phases de modélisation.

4. Analyse descriptive

Les statistiques descriptives des principales variables liées à la performance montrent :

- **Impressions :**

Moyenne $\approx$ 5 704, médiane $\approx$ 4 289, min = 1 941, max = 36 919.

- **Likes :**

Moyenne $\approx$ 174, médiane $\approx$ 151, min = 72, max = 549.

- **Comments :**

Moyenne $\approx$ 6,7, entre 0 et 19.

- **Shares :**

Moyenne $\approx$ 9,4, entre 0 et 75.

- **Saves :**


Moyenne $\approx$ 153, médiane $\approx$ 109, max = 1 095.

- **Engagement :**

Moyenne $\approx$ 3,74%, médiane $\approx$ 3,78%, quartiles 25% $\approx$ 3,15%, 75% $\approx$ 4,25%, min $\approx$ 1,28%, max $\approx$ 6,0%

5. Analyse des corrélations

Nous étudions les corrélations entre les différentes variables quantitatives afin d'identifier des relations potentielles avec l'engagement.




La matrice de corrélation entre les variables quantitatives (Impressions, Likes, Comments, Shares, Saves, engagement) met en évidence :

- Une forte corrélation positive entre Impressions et Likes ($\approx$ 0,85), ainsi qu'entre Likes et Saves ($\approx$ 0,85), ce qui indique que les posts les plus vus sont aussi ceux qui génèrent le plus de likes et de sauvegardes.
- Des corrélations également élevées entre Impressions et Saves ($\approx$ 0,78) et entre Shares et Saves ($\approx$ 0,86), suggérant que les posts très diffusés ont tendance à être davantage partagés et sauvegardés.
- Une corrélation négative entre Impressions et engagement ($\approx$ -0,54) et plus modérée entre Likes et engagement ($\approx$ -0,21), ce qui indique que les posts les plus visibles ne sont pas forcément ceux qui ont le meilleur taux d'engagement relatif.
- Une corrélation légèrement positive entre Comments et engagement ($\approx$ 0,25), montrant que les posts avec plus de commentaires ont souvent un meilleur engagement relatif.

6. Analyse graphique des facteurs de contenu


Nous analysons l'impact de certaines caractéristiques du contenu sur le taux d'engagement.

6.1 Engagement en fonction du nombre de hashtags



Le taux d'engagement reste globalement compris entre 2% et 6% pour des nombres de hashtags allant d'environ 10 à 30. On observe une dispersion importante : certains posts avec peu de hashtags obtiennent un bon engagement, tandis que d'autres avec beaucoup de hashtags performant moins bien. Cela suggère que la qualité et la pertinence des hashtags comptent probablement davantage que leur quantité.


6.2 Engagement en fonction de la longueur de la légende



Quelques posts avec des légendes très longues (au-delà de 400–500 caractères) n’obtiennent pas de meilleurs résultats, leur engagement restant dans la même fourchette que les autres, voire légèrement plus faible. Globalement, il n’apparaît **pas de relation croissante** entre la longueur de la légende et le taux d’engagement ; des légendes très longues ne semblent donc pas apporter de gain d’engagement par rapport à des légendes courtes ou moyennes.

7. Analyse des sources d’impressions

Nous analysons la contribution des différentes sources (Home, Hashtags, Explore, Other) aux impressions totales.



Le graphique en barres montre que la page d’accueil et les hashtags sont les deux principales sources de visibilité des posts, ce qui laisse penser que la stratégie de hashtags et la qualité du contenu pour le fil d’actualité sont des leviers importants pour l’engagement.

En moyenne, les impressions proviennent principalement de From Home ($\approx 2\,476$ impressions) et From Hashtags ($\approx 1\,888$), puis de From Explore ($\approx 1\,078$) et marginalement de From Other (≈ 171).

8. Conclusion

L'analyse exploratoire a permis de mieux comprendre la structure Du jeu de données et les principaux facteurs liés à l'engagement.

Les résultats montrent que l'engagement dépend à la fois de la visibilité du post (impressions, sources) et des caractéristiques du contenu (nombre de hashtags, longueur de la légende).

Phase 3 : Modélisation statistique (Régression)

L'objectif de cette phase est de construire un modèle statistique permettant d'expliquer le taux d'engagement d'un post Instagram à partir de ses caractéristiques.

1. Rappel des variables

La variable à expliquer **Y** est le taux d'engagement engagement

Les variables explicatives **X** retenues pour le premier modèle de régression sont :

- **hashtags_count** : nombre de hashtags utilisés dans le post ;
- **caption_length** : longueur de la légende en nombre de caractères ;
- **Impressions** : nombre total d'impressions du post.

2. Modèle de régression linéaire

Nous utilisons une régression linéaire afin d'expliquer le taux d'engagement en fonction des variables sélectionnées.

Coefficient de détermination R²

Le coefficient de détermination R² est de 0.34, ce qui indique que le modèle explique une part modérée de la variabilité du taux d'engagement, ce qui reste cohérent avec la complexité du comportement des utilisateurs sur Instagram.

Les coefficients obtenus sont :

Variable	Coefficient
hashtags_count	$2,62 \times 10^{-4}$
caption_length	$-1,38 \times 10^{-5}$
Impressions	$-9,69 \times 10^{-7}$

L'ajustement montre que, toutes choses égales par ailleurs, le nombre de hashtags est associé positivement au taux d'engagement, tandis que la longueur de la légende et le nombre d'impressions sont associés négativement.

Interprétation qualitative :

- hashtags_count (coefficient positif) : chaque hashtag supplémentaire augmente légèrement le taux d'engagement, ce qui indique que les hashtags contribuent à toucher un public plus réactif à contenu constant.
- caption_length (coefficient négatif) : les légendes plus longues sont associées à un engagement légèrement plus faible, ce qui peut suggérer que les utilisateurs réagissent mieux à des messages plus concis.
- Impressions (coefficient négatif) : plus un post est vu, plus le taux d'engagement tend à diminuer, ce qui confirme les corrélations négatives observées en Phase 2 : les

posts très exposés ne transforment pas forcément cette visibilité en interactions proportionnelles.

3. Discussion et limites

Le modèle linéaire repose sur des hypothèses de linéarité, d'homoscédasticité et de normalité des résidus, qui ne sont pas parfaitement vérifiées compte tenu du faible effectif (119 posts) et de la présence de valeurs extrêmes en impressions.

Phase 4 – Modélisation statistique (classification)

L'objectif de cette phase est de classer les publications Instagram selon leur niveau d'engagement, en distinguant les posts à fort engagement des autres.

1. Construction de la variable binaire

high_engagement	Count
0	60
1	59

Pour la classification, nous définissons une variable binaire `high_engagement` indiquant si un post présente un taux d'engagement élevé ou non.

Le seuil retenu est basé sur la distribution du taux d'engagement (par exemple au-dessus du 75e percentile ou défini par l'enseignant), ce qui donne un échantillon presque équilibré : 60 posts à engagement normal 0 et 59 posts à fort engagement 1.

2. Modèles de classification à utiliser

- Régression logistique.
- Arbre de décision.

Régression logistique

- Classe 0 : précision 0,78, rappel 0,78, F1 = 0,78
- Classe 1 : précision 0,78, rappel 0,78, F1 = 0,78
- Accuracy globale = 0,78 (28/36 bien classés).

Interprétation :

- Le modèle prédit correctement 78% des posts du jeu de test.
- Pour la classe « fort engagement » 1 :
 - Précision 0,78 → parmi les posts prédits comme « fort engagement », 78% le sont vraiment ;
 - Rappel 0,78 → le modèle retrouve 78% de tous les posts réellement « fort engagement ».
- Le modèle est équilibré : il traite à peu près aussi bien les posts à faible et à fort engagement.

Arbre de décision

L'arbre de décision atteint la même performance (78% de bonnes prédictions) mais offre une lecture plus intuitive sous forme de règles, au prix d'une stabilité un peu moindre si on complexifie l'arbre

3. Comparaison des deux modèles

Les deux modèles obtiennent la même matrice de confusion sur le jeu de test (14 vrais négatifs, 14 vrais positifs, 4 faux positifs et 4 faux négatifs), soit une accuracy de 78%. La régression logistique se distingue par une meilleure stabilité et une interprétation simple via

ses coefficients, tandis que l'arbre de décision fournit des règles explicites facilement compréhensibles par un public non technique.

La régression logistique offre une meilleure stabilité et une interprétation plus simple des résultats, tandis que l'arbre de décision permet une lecture plus intuitive des règles de décision.

Le choix du modèle dépend donc du compromis souhaité entre performance et interprétabilité.


Phase 5 – Analyse temporelle

L'objectif de cette phase est d'étudier l'évolution du taux d'engagement dans le temps afin d'identifier d'éventuelles tendances ou patterns temporels.

Le dataset utilisé ne contient pas de variables temporelles. Afin d'illustrer la méthodologie des séries chronologiques, nous avons simulé des dates de publication pour les différentes observations.

Cette approche permet d'analyser l'évolution de l'engagement dans le temps, de détecter des patterns hebdomadaires éventuels et de réaliser une prévision à court terme à l'aide d'un modèle ARIMA.

1. L'évolution du taux d'engagement



Interprétation statistique


Le graphique représente l'évolution simulée du taux d'engagement des publications au cours du temps. On observe que l'engagement fluctue autour d'une valeur moyenne située approximativement entre **3 % et 4 %**.

Certaines observations présentent des pics d'engagement pouvant atteindre environ **6 %**, tandis que d'autres descendent jusqu'à environ **2 %**. Cette dispersion montre que la performance des publications varie significativement d'un post à l'autre.

Dans l'ensemble, aucune tendance clairement croissante ou décroissante n'apparaît sur toute la période. Le taux d'engagement oscille autour d'un niveau relativement stable, ce qui suggère l'absence de tendance temporelle forte.

Les variations observées peuvent s'expliquer par plusieurs facteurs, comme la qualité du contenu, la visibilité du post, l'utilisation de hashtags ou encore le niveau d'interaction des utilisateurs.

2. Engagement par jour de la semaine



Interprétation statistique

On observe que **mardi et mercredi** présentent les niveaux d'engagement moyen les plus élevés, proches de **4 %**, ce qui suggère que ces journées pourraient être légèrement plus favorables à la publication de contenu.


À l'inverse, **vendredi et dimanche** affichent des valeurs légèrement plus faibles, autour de **3,6 %**.

Cependant, l'écart entre les différents jours reste limité (**≈ 0,4 point de pourcentage**), ce qui indique qu'il n'existe pas de différence très marquée entre les jours de la semaine.

D'un point de vue statistique, cela suggère que **le jour de publication n'est probablement pas le facteur principal influençant l'engagement**. Les performances des publications semblent plutôt dépendre d'autres variables telles que la visibilité du post, le contenu, les hashtags ou le nombre d'impressions.

Ces résultats montrent néanmoins que publier en milieu de semaine pourrait légèrement améliorer la probabilité d'obtenir un engagement plus élevé.

3. La tendance du taux d'engagement



Interprétation

Le graphique présente l'évolution du taux d'engagement (courbe bleue) ainsi que sa moyenne mobile (courbe orange), qui permet de lisser les variations observées entre les différentes publications.

La série d'engagement montre des fluctuations importantes, avec des valeurs comprises approximativement entre **2 % et 6 %**. Ces variations traduisent une forte variabilité des performances d'un post à l'autre.

La moyenne mobile permet d'identifier la tendance générale. Elle montre que l'engagement reste globalement stable autour de **3,5 % à 4 %** pendant une grande partie de la période. Cependant, une légère diminution apparaît vers la fin de la série, suggérant une baisse progressive de l'engagement sur les dernières observations.

Cette analyse permet de mieux comprendre la tendance globale en réduisant l'effet des fluctuations aléatoires observées dans les données brutes.

4. Prévisions ARIMA

	predicted_mean
119	0.023905
120	0.023651
121	0.023657
122	0.023657
123	0.023657
124	0.023657
125	0.023657
126	0.023657
127	0.023657
128	0.023657

dtype: float64

Interpretation

Les prévisions du modèle ARIMA indiquent que le taux d'engagement devrait se stabiliser autour de **2,36 %** dans les prochaines observations.

La première valeur prédite est d'environ **2,39%**, puis les valeurs se stabilisent rapidement.

Cela suggère l'absence de tendance forte d'augmentation ou de diminution de l'engagement à court terme. Les variations observées semblent donc principalement aléatoires.

Phase 6 – Interprétation statistique et recommandations

1. Interprétation statistique des résultats

L'analyse exploratoire (Phase 2) a mis en évidence une forte variabilité entre les publications en termes de visibilité (Impressions) et d'engagement (engagement). Les statistiques descriptives montrent que certains posts génèrent beaucoup plus de likes, commentaires, partages et sauvegardes que d'autres, ce qui confirme des différences de performance marquées entre contenus.

Les analyses de corrélation montrent des relations positives entre les impressions et les indicateurs d'interaction (likes, partages, sauvegardes), mais une corrélation négative entre le volume d'impressions et le taux d'engagement relatif. Cela signifie que les posts très visibles ne sont pas forcément ceux qui transforment le mieux cette visibilité en interactions proportionnelles.

La régression linéaire (Phase 3) a permis de quantifier l'impact de certaines variables sur le taux d'engagement. Les coefficients estimés indiquent notamment que : le nombre de hashtags est associé positivement à l'engagement, tandis que la longueur de la légende et le volume d'impressions ont un effet négatif, toutes choses égales par ailleurs. Le coefficient de détermination R^2 montre que le modèle explique une part significative, mais non exhaustive, de la variabilité du taux d'engagement, ce qui est cohérent avec la complexité des comportements sur les réseaux sociaux.

Les modèles de classification (Phase 4) ont permis de distinguer les publications à fort engagement des autres à partir de variables explicatives simples. Les matrices de confusion et les mesures de performance indiquent que les modèles classent correctement une majorité de posts, tout en commettant des erreurs, ce qui illustre les limites de modèles relativement simples sur un échantillon de taille modeste, mais confirme l'existence de profils de posts plus performants que d'autres.

2. Recommandations stratégiques

À partir des résultats obtenus, plusieurs recommandations peuvent être formulées pour le client :

- Ajuster la longueur des légendes : privilégier des textes suffisamment informatifs sans être trop longs, car des légendes très longues sont associées à une diminution du taux d'engagement.
- Utiliser les hashtags de manière stratégique : un nombre modéré et pertinent de hashtags est corrélé à un meilleur engagement, alors qu'un usage non ciblé risque d'être moins efficace.
- Travailler les sources de visibilité : les impressions issues de la page d'accueil et surtout des hashtags et de l'onglet Explore constituent des leviers importants ; optimiser la stratégie de hashtags et la qualité du contenu pour favoriser ces sources peut renforcer à la fois la portée et l'engagement.
- Capitaliser sur les posts à fort engagement : analyser les posts identifiés comme « high_engagement » par les modèles de classification (thèmes, types de contenus, style de légende, structure des hashtags) afin de reproduire leurs caractéristiques dans les futures campagnes.

Conclusion

Ce projet avait pour objectif d'analyser les facteurs influençant l'engagement des publications Instagram à partir d'un jeu de données de 119 posts. L'analyse exploratoire a permis de mieux comprendre la structure des données et de mettre en évidence la variabilité des performances entre les publications.

Les modèles statistiques utilisés, notamment la régression et la classification, ont permis d'identifier l'influence de certaines variables comme le nombre de hashtags, la longueur de la légende et le niveau de visibilité des posts. L'analyse temporelle a également montré que le taux d'engagement reste globalement stable dans le temps, avec des variations principalement liées aux caractéristiques des publications.

Ces résultats permettent de formuler des recommandations pour améliorer la stratégie de publication sur Instagram, notamment en optimisant l'utilisation des hashtags, en adaptant la longueur des légendes et en analysant les publications les plus performantes.